Fairness en Machine Learning

Group fairness

Anuncios/Comentarios

- Devolucion o comentarios de encuestas
- Fechas importantes:
  - Presentación preliminar del TP: 16/04
  - Primer parcial: 30/04 (Presencial para estudiantes de UNSAM)
  - Recuperatorio del primer parcial: 14/05 (Presencial para estudiantes de UNSAM)
  - Entrega del TP por mail: 25/05 hasta las 23:59
  - Defensa del TP: 28/05
  - Segundo parcial: 04/06 (Presencial para estudiantes de UNSAM)
  - Recuperatorio del segundo parcial: 18/06 (Presencial para estudiantes de UNSAM)

  El TP tendrá una instancia de recuperatorio que quedará a convenir según la situación, posible fecha de recuperatorio del TP: 11/06

- Lectura conjuta del TP
  - Ideas de slides:

Objetivos

1. Definición de métricas de evaluación.
2. *Group fairness.*

Group fairness

Taxonomía de los criterios de *fairness*

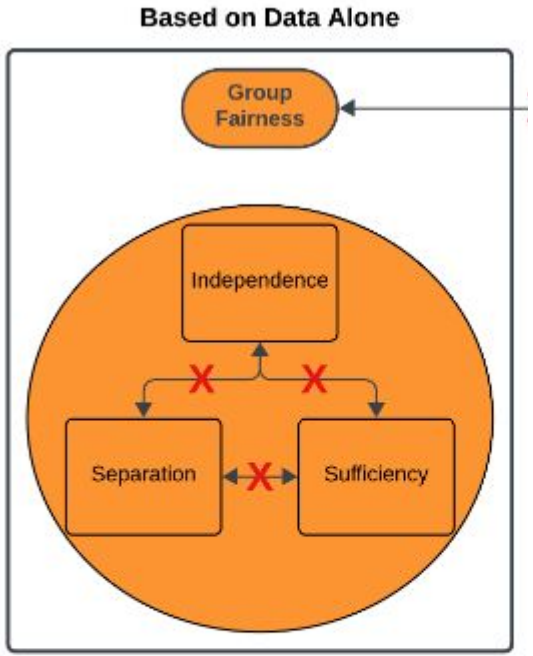

- **Group Fairness**: este enfoque se centra en garantizar la equidad entre los grupos de interés. Su objetivo es definir una métrica que se utilice para comparar la performance del modelo entre grupos.

- Hay tres nociones principales:
  - independencia
  - separación
  - suficiencia

Procedimiento para analizar *group fairness* – – –

1. Selección de una métrica
2. Dividir al conjunto test de acuerdo a las categorías que nos interesa analizar si el modelo es equitativo.
3. Evaluar con la métrica seleccionada en 1. cada grupo
4. Comparar las performance (diferencia o ratio).
5. Elegir un umbral y concluir si el modelo es equitativo bajo la definición seleccionada en el punto 1 y el umbral seleccionado.

Ejemplo: cómo analizar group fairness

---

0. Consideremos el siguiente dataset

Atributo sensible	a	a	a	a	a	a	a	a	a	a	b	b	b	b	b
Y	1	1	1	1	1	0	0	0	0	0	1	1	1	0	0
Ŷ	1	1	1	1	0	0	0	0	0	0	1	0	0	1	1

1. Selección de una métrica: accuracy

Ejemplo: cómo analizar group fairness

---

1. Selección de una métrica
2. Dividir al conjunto test de acuerdo a las categorías que nos interesa analizar si el modelo es fair.

	a	a	a	a	a	a	a	a	a	a
Y	1	1	1	1	1	0	0	0	0	0
Ŷ	1	1	1	1	0	0	0	0	0	0

	b	b	b	b	b
Y	1	1	1	0	0
Ŷ	1	0	0	1	1

Ejemplo: cómo analizar group fairness

---

1. Selección de una métrica
2. Dividir al conjunto test de acuerdo a las categorías que nos interesa analizar si el modelo es fair.
3. Evaluar con la métrica seleccionada en 1. cada grupo

	a	a	a	a	a	a	a	a	a	a
Y	1	1	1	1	1	0	0	0	0	0
Ŷ	1	1	1	1	0	0	0	0	0	0

	b	b	b	b	b
Y	1	1	1	0	0
Ŷ	1	0	0	1	1

$accuracy_a = 9/10$

$accuracy_b = 1/5$

Ejemplo: cómo analizar group fairness

---

1. Selección de una métrica
2. Dividir al conjunto test de acuerdo a las categorías que nos interesa analizar si el modelo es fair.
3. Evaluar con la métrica seleccionada en 1. cada grupo
4. Comparar las performance (diferencia o ratio)

$accuracy_a$=9/10 $accuracy_b$=1/5

Si consideramos el módulo de la diferencia: |9/10-1/5|=0,7

Ejemplo: cómo analizar group fairness

---

1. Selección de una métrica
2. Dividir al conjunto test de acuerdo a las categorías que nos interesa analizar si el modelo es fair.
3. Evaluar con la métrica seleccionada en 1. cada grupo
4. Comparar las performance (diferencia o ratio).
5. Se elige un umbral y se concluye si el modelo es fair bajo la definición seleccionada en el punto 1 y el umbral seleccionado.

   umbral seleccionado=0,1

   ¿ |9/10-1/5|< umbral? No, enonces el modelo no es fair en este caso.

Group fairness: definición de métricas

Independencia	**Separación**	**Suficiencia**
$\hat{Y} \perp A$	$\hat{Y} \perp A \mid Y$	$Y \perp A \mid \hat{Y}$
La predicción \hat{Y} Y^ es estadísticamente independiente del atributo sensible A.	La predicción Y^\hat{Y} Y^ es independiente de A *condicional* al resultado verdadero Y	El resultado verdadero Y es independiente de A *condicional* a la predicción \hat{Y}

Statistical parity

- Criterio de **independencia** ($\hat{Y} \perp A$)

- Statistical Parity / Demographic Parity (Asumiendo problema de clasificación binaria):

$$P(\hat{Y} = 1|A = a) = P(\hat{Y} = 1|A = b) \quad \forall\ a, b \in A$$

Statistical parity - Ejemplo

- Statistical Parity / Demographic Parity (Asumiendo problema de clasificación binaria):

$$P(\hat{Y} = 1|A = a) = P(\hat{Y} = 1|A = b) \quad \forall\ a, b \in A$$

	a	a	a	a	a	a	a	a	a	a
Y	1	1	1	1	1	0	0	0	0	0
$\hat{Y}$	1	1	1	1	0	0	0	0	0	0

$$P(\hat{Y} = 1|A = a) = 4/10 = 2/5$$

	b	b	b	b	b
Y	1	1	1	0	0
$\hat{Y}$	1	0	0	1	1

$$P(\hat{Y} = 1|A = b) = 3/5$$

Statistical parity - Ejemplo

	a	a	a	a	a	a	a	a	a	a
Y	1	1	1	1	1	0	0	0	0	0
Ŷ	1	1	1	1	0	0	0	0	0	0

	b	b	b	b	b
Y	1	1	1	0	0
Ŷ	1	0	0	1	1

$P(\hat{Y} = 1|A = a) = 4/10 = 2/5$

$P(\hat{Y} = 1|A = b) = 3/5$

- Para concluir si el modelo es fair bajo la definición de Statistical Parity, seleccionamos un umbral y un criterio de comparación y concluímos.
  - umbral = 0,1
  - método de comparación: módulo de la diferencia

=> $|\frac{2}{5}-\frac{3}{5}| = \frac{1}{5} = 0{,}2$. Ahora nos preguntamos ¿0,2 < umbral? No. Entonces, concluímos que este modelo no es fair según Statistical Parity considerando el umbral =0,1.

Equalized Odds

- Criterio de **separación**: $\hat{Y} \perp A \mid Y$

- Equalized Odds (asumiendo problema de clasificación binaria):

$$P(\hat{Y} = 1 | A = a, Y = y) = P(\hat{Y} = 1 | A = b, Y = y) \quad \forall\ a, b \in A, y \in \{0,1\}$$

Equalized Odds

- $P(\hat{Y} = 1|A = a, Y = y) = P(\hat{Y} = 1|A = b, Y = y) \quad \forall\ a, b \in A, y \in \{0,1\}$

1. $P(\hat{Y} = 1|A = a, Y = 1) = P(\hat{Y} = 1|A = b, Y = 1) \quad \forall\ a, b \in A$

   $\Rightarrow TPR_a = TPR_b$

2. $P(\hat{Y} = 1|A = a, Y = 0) = P(\hat{Y} = 1|A = b, Y = 0) \quad \forall\ a, b \in A$

   $\Rightarrow FPR_a = FPR_b$

Equalized Odds - Ejemplo

- $TPR_a = TPR_b$

	a	a	a	a	a	a	a	a	a	a
Y	1	1	1	1	1	0	0	0	0	0
$\hat{Y}$	1	1	1	1	0	0	0	0	0	0

	b	b	b	b	b
Y	1	1	1	0	0
$\hat{Y}$	1	0	0	1	1

$TPR_a = P(\hat{Y} = 1 | A = a, Y = 1) = 4/5$

$TPR_b = P(\hat{Y} = 1 | A = b, Y = 1) = 1/3$

Equalized Odds - Ejemplo

- $FPR_a = FPR_b$

	a	a	a	a	a	a	a	a	a	a
Y	1	1	1	1	1	0	0	0	0	0
$\hat{Y}$	1	1	1	1	0	0	0	0	0	0

	b	b	b	b	b
Y	1	1	1	0	0
$\hat{Y}$	1	0	0	1	1

$FPR_a = P(\hat{Y} = 1|A = a, Y = 0) = 0/5$

$FPR_b = P(\hat{Y} = 1|A = b, Y = 0) = 2/2$

Equalized Odds - Ejemplo

- $TPR_a = P(\hat{Y} = 1 | A = a, Y = 1) = 4/5$ $TPR_b = P(\hat{Y} = 1 | A = b, Y = 1) = 1/3$

- $FPR_a = P(\hat{Y} = 1 | A = a, Y = 0) = 0/5$ $FPR_b = P(\hat{Y} = 1 | A = b, Y = 0) = 2/2$

➔ Para concluir si el modelo es fair bajo la definición de Equalized Odds seleccionamos un umbral y un criterio de comparación y concluímos.
  - umbral = 0,1
  - método de comparación: módulo de la diferencia

  Como ahora tenemos dos métricas (TPR y FPR) se tiene que satisfacer para ambos casos, si falla para alguno de los casos o para los dos diremos que no es fair segun Equalized Odds considerando el umbral seleccionado y el criterio de comparacion seleccionado

Equalized Odds - Ejemplo

- $TPR_a = P(\hat{Y} = 1|A = a, Y = 1) = 4/5$
- $FPR_a = P(\hat{Y} = 1|A = a, Y = 0) = 0/5$

$TPR_b = P(\hat{Y} = 1|A = b, Y = 1) = 1/3$

$FPR_b = P(\hat{Y} = 1|A = b, Y = 0) = 2/2$

➔ Para concluir si el modelo es fair bajo la definición de Equalized Odds seleccionamos un umbral y un criterio de comparación y concluímos.

- umbral = 0,1
- método de comparación: módulo de la diferencia

Como ahora tenemos dos métricas (TPR y FPR) se tiene que satisfacer para ambos casos, si falla para alguno de los casos o para los dos diremos que no es fair segun Equalized Odds considerando el umbral seleccionado y el criterio de comparacion seleccionado

TPR => $|4/5 - 1/3| = 0{,}4666$

FPR => $|0 - 1| = 1$

Equalized Odds - Ejemplo

- $TPR_a = P(\hat{Y} = 1 | A = a, Y = 1) = 4/5$
- $FPR_a = P(\hat{Y} = 1 | A = a, Y = 0) = 0/5$

$TPR_b = P(\hat{Y} = 1 | A = b, Y = 1) = 1/3$

$FPR_b = P(\hat{Y} = 1 | A = b, Y = 0) = 2/2$

➔ Para concluir si el modelo es fair bajo la definición de Equalized Odds seleccionamos un umbral y un criterio de comparación y concluímos.

- umbral = 0,1
- método de comparación: módulo de la diferencia

Como ahora tenemos dos métricas (TPR y FPR) se tiene que satisfacer para ambos casos, si falla para alguno de los casos o para los dos diremos que no es fair segun Equalized Odds considerando el umbral seleccionado y el criterio de comparacion seleccionado

TPR => ¿ $|4/5 - 1/3| = 0{,}4666 <$ umbral? ❌

FPR => ¿$|0 - 1| = 1 <$ umbral?❌

=> Entonces, concluímos que este modelo no es fair según Equalized Odds considerando el umbral =0,1.

Equal Opportunity

- Versión **relajada** del criterio de **separación**

- Equal Opportunity (asumiendo problema de clasificación binaria):

$$P(\hat{Y} = 0|A = a, Y = 1) = P(\hat{Y} = 0|A = b, Y = 1) \quad \forall\ a, b \in A$$

$$\Rightarrow TPR_a = TPR_b$$

Equal Opportunity - Ejemplo

- $TPR_a = TPR_b$

	a	a	a	a	a	a	a	a	a	a
Y	1	1	1	1	1	0	0	0	0	0
$\hat{Y}$	1	1	1	1	0	0	0	0	0	0

	b	b	b	b	b
Y	1	1	1	0	0
$\hat{Y}$	1	0	0	1	1

$TPR_a = P(\hat{Y} = 1 | A = a, Y = 1) = 4/5$

$TPR_b = P(\hat{Y} = 1 | A = b, Y = 1) = 1/3$

Ratio Falsos Positivos

- Asumiendo problema de clasificación binaria:

$$P(\hat{Y} = 1|A = a, Y = 0) = P(\hat{Y} = 1|A = b, Y = 0) \ \forall \ a, b \in A$$

- $FP_a / (FP_a + TN_a) = FP_b / (FP_b + TN_b)$

$$\Rightarrow FPR_a = FPR_b$$

		Realidad (Y)	
		Positivo Y= 1	
Predicción Ŷ	Positivo Ŷ = 1	TP	FP
	Negativo Ŷ=0	FN	TN

Ratio Falsos Positivos - Ejemplo

- $FPR_a = FPR_b$

	a	a	a	a	a	a	a	a	a	a
Y	1	1	1	1	1	0	0	0	0	0
$\hat{Y}$	1	1	1	1	0	0	0	0	0	0

	b	b	b	b	b
Y	1	1	1	0	0
$\hat{Y}$	1	0	0	1	1

$FPR_a = P(\hat{Y} = 1|A = a, Y = 0) = 0/5$

$FPR_b = P(\hat{Y} = 1|A = b, Y = 0) = 2/2$

Ratio Falsos Positivos - Ejemplo

- $FPR_a = P(\hat{Y} = 1 | A = a, Y = 0) = 0/5$ $FPR_b = P(\hat{Y} = 1 | A = b, Y = 0) = 2/2$

➔ Para concluir si el modelo es fair bajo la definición de Ratio Falsos Positivos seleccionamos un umbral y un criterio de comparación y concluímos.

- umbral = 0,1
- método de comparación: módulo de la diferencia

FPR => ¿|0 -1 |= 1< umbral?❌

=> Entonces, concluímos que este modelo no es equitativo según el Ratio de Falsos Positivos considerando el umbral =0,1.

Predictive Parity

- Criterio de suficiencia relajada: $Y \perp A \mid \hat{Y}$

- Predictive parity (asumiendo problema de clasificación binaria):

  $P(Y = 1|A = a, \hat{Y} = 1) = P(Y = 1| A = b, \hat{Y} = 1) \quad \forall\ a, b \in A$

  Positive Predictive Value A = Positive Predictive Value B

$$TP_a / (FP_a + TP_a) = TP_b / (FP_b + TP_b)$$

Predictive Parity - Ejemplo

- $P(Y = 1|A = a, \hat{Y} = 1) = P(Y = 1| A = b, \hat{Y} = 1) \quad \forall\ a, b \in A$

Positive Predictive Value A = Positive Predictive Value B

$TP_a / (FP_a + TP_a) = TP_b / (FP_b + TP_b)$

	a	a	a	a	a	a	a	a	a	a
Y	1	1	1	1	1	0	0	0	0	0
$\hat{Y}$	1	1	1	1	0	0	0	0	0	0

	b	b	b	b	b
Y	1	1	1	0	0
$\hat{Y}$	1	0	0	1	1

$P(Y = 1|A = a, \hat{Y} = 1) = 4/4 = 1$

$P(Y = 1| A = b, \hat{Y} = 1) = 1/3$

Predictive Parity - Ejemplo

- $P(Y = 1|A = a, \hat{Y} = 1) = P(Y = 1| A = b, \hat{Y} = 1) \quad \forall\ a, b \in A$

	a	a	a	a	a	a	a	a	a	a
Y	1	1	1	1	1	0	0	0	0	0
$\hat{Y}$	1	1	1	1	0	0	0	0	0	0

	b	b	b	b	b
Y	1	1	1	0	0
$\hat{Y}$	1	0	0	1	1

$P(Y = 1|A = a, \hat{Y} = 1) = 4/4 = 1$

$P(Y = 1| A = b, \hat{Y} = 1) = 1/3$

- Para concluir si el modelo es fair bajo la definición de Predictive Parity, seleccionamos un umbral y un criterio de comparación y concluímos.
  - umbral = 0,1
  - método de comparación: módulo de la diferencia

=> |1-1/3|=2/3 = 0,. Ahora nos preguntamos ¿0, < umbral? No. Entonces, concluímos que este modelo no es fair según Predictive Parity, considerando el umbral =0,1 y el método de comparación módulo de la diferencia.

Ejemplos de interpretación

COMPAS

- Variable protegida/ sensible: race (Caucasian vs Afroamerican)
- ¿Qué busca predecir el modelo?
- ¿Qué representa la clase positiva?

Predicción \ Realidad	Positivo	Negativo
Positivo	TP Persona identificada como de alto riesgo que reinicide.	**FP** **Persona identificada como de alto riesgo que no reincide.**
Negativo	FN Persona que es identificada como no riesgosa que reincide.	TN Persona que no es identificada como de altoriesgo que no reincide

¿Daños?

¿Daños?

Desidentificación

Falso Positivo

Input: Visita a domicilio **Av. Rivadavia 742**.

Output: **XXX** a domicilio **XXX**.

❌ ✅ ✅ ✅

Falso Negativo

Input: Visita a domicilio **Av. Rivadavia 742**.

Output: Visita a domicilio **Av. Rivadavia 742**.

✅ ✅ ✅ ❌

Desidentificación

Falso Positivo

Input: Visita a domicilio **Av. Rivadavia 742**.

Output: **XXX** a domicilio **XXX**.

❌ ✅ ✅ ✅

Falso Negativo

Input: Visita a domicilio **Av. Rivadavia 742**.

Output: Visita a domicilio **Av. Rivadavia 742**.

✅ ✅ ✅ ❌

¿Qué potenciales daños podría tener la aplicación de este sistema?

Statistical parity - Intepretación

- Statistical Parity / Demographic Parity (Asumiendo problema de clasificación binaria):

$$P(\hat{Y} = 1|A = a) = P(\hat{Y} = 1|A = b)$$

$$\forall\ a, b \in A$$

- COMPAS

  Proporción de personas etiquetadas como reincidentes.

- Desifentificación

  Proporción de entidades etiquetadas como sensibles.

		Realidad	
		Positivo	Negativo
Predicción	Positivo	TP	FP
	Negativo	FN	TN

$$(TP_a+FP_a)/(FP_a+TP_aTP_a+FN_a)=$$
$$(TP_b+FP_b)/(FP_b+TP_b+TN_b+FN_b)$$

Ratio Falsos Positivos - Interpretación

- Asumiendo problema de clasificación binaria:

$$P(\hat{Y} = 1|A = a, Y = 0) = P(\hat{Y} = 1|A = b, Y = 0) \quad \forall\ a, b \in A$$

- $FP_a / (FP_a + TN_a) = FP_b / (FP_b + TN_b) \Rightarrow FPR_a = FPR_b$

		Realidad (Y)	
		Positivo Y= 1	Negativo Y= 0
Predicción Ŷ	Positivo Ŷ = 1	TP	FP
	Negativo Ŷ=0	FN	TN

Interpretación:

- **COMPAS**: De las personas que no reinciden qué proporción fue erroneamente clasificada como reincidente.
- **Desifentificación**: Del conjunto de entidades que no son sensibles qué proporción fue clasficada como sensible.

Equal Opportunity - Interpretación

- Equal Opportunity (asumiendo problema de clasificación binaria):

$$P(\hat{Y} = 0|G = a, Y = 1) = P(\hat{Y} = 0|G = b, Y = 1) \quad \forall\ a, b \in A$$

- $TP_a/(TP_a+FN_a) = TP_b/(TP_b+FN_b) \Rightarrow TPR_a = TPR_b$

		Realidad (Y)	
		Positivo Y= 1	Negativo Y=0
Predicción Ŷ	Positivo Ŷ = 1	TP	FP
	Negativo Ŷ=0	FN	TN

Intepretaciones:

- **COMPAS** :De las personas que reinciden qué proporción fue correctamente identificada.
- **Desifentificación**: Del conjunto de entidades sensibles qué proporción fue correctamente identificada.

Predictive Parity - Interpretación

- Predictive parity (asumiendo problema de clasificación binaria):

$$P(Y = 1|A = a, \hat{Y} = 1) = P(Y = 1| A = b, \hat{Y} = 1) \quad \forall\ a, b \in A$$

- $TP_a / (FP_a + TP_a) = TP_b / (FP_b + TP_b)$

		Realidad	
		Positivo	Negativo
Predicción	Positivo	TP	FP
	Negativo	FN	TN

Interpretación:

- **COMPAS:** De las personas que el modelo predice que reincidirán qué proporción fue correctamente identificada.
- **Desifentificación**:Del conjunto de palabras etiquetadas como entidades sensibles qué proporción fue correctamente identificada.

¿Qué criterio utilizarían para COMPAS?

Criterio	Interpretación
Ratio falsos positivos	De las personas que no reinciden qué proporción fue erroneamente clasificada como reincidente.
Equal Opportunity	De las personas que reinciden qué proporción fue correctamente identificada.
Predictive Parity	De las personas que el modelo predice que reincidirán qué proporción fue correctamente identificada.
Statistical Parity	Proporción de personas etiquetadas como reincidentes.

¿Qué criterio utilizarían para COMPAS?

Criterio	Interpretación
Ratio falsos positivos	De las personas que no reinciden a qué proporción no se le otorgará libertad condicional.
Equal Opportunity	De las personas que reinciden a qué proporción no se le otorgó libertad condicional
Predictive Parity	De las personas que se les otorgará libertad condicional qué proporción reincidirían.
Statistical Parity	Proporción de personas a las que no se les otorga libertad condicional.

¿y para el problema de desidentificación?

Criterio	Interpretación
Ratio falsos positivos	Del conjunto de entidades que no son sensibles qué proporción fue clasficada como sensible.
Equal Opportunity	Del conjunto de entidades sensibles qué proporción fue correctamente identificada.
Predictive Parity	Del conjunto de palabras etiquetadas como entidades sensibles qué proporción fue correctamente identificada.
Statistical Parity	Proporción de entidades etiquetadas como sensibles.

¿y para el problema de desidentificación?

Criterio	Interpretación
Ratio falsos positivos	Del conjunto de entidades que no son sensibles qué proporción será censurada.
Equal Opportunity	Del conjunto de entidades sensibles qué proporción será censurada-.
Predictive Parity	Del conjunto de palabras censuradas qué proporción eran entidades sensibles.
Statistical Parity	Proporción de entidades censuradas

Declaración de posición de *fairness*

Definición	Nuestro equipo eligio _____ como definición de *fairness*.
Justificación	Elegimos esta métrica porque _____.
Resultado	Remasterizar el modelo hacia esta medida garantizará que _____ .

Ejercicio de interpretación

15 minutos

Ingresar al siguiente link e interpretar cada criterio de equidad para ese contexto.

Selección de umbrales

- Umbrales que aparecen en la literatura:
  - 0,05
  - 0,1 en contextos de datasets “pequeños” o muy desbalanceados
  - cuando se usa el ratio en vez de la diferencia, puede aparecer 0,8 (por ejemplo: TPRa/ TPRb ≥ 0,8) conocida como la regla de los ⅘.
    - este umbral está basado en leyes laborales de EEUU

¿Se les ocurren otras consideraciones?

- Algunas ideas de cómo elegirlo:
  - tamaño del grupo minoritario
  - contexto regulatorio
  - Tomar como base la diferencia o ratio entre grupos obtenido por un modelo previo (Sugerido por Leila)

Práctica
Notebook usando FairLearn

Árbol de decisión para elegir métricas

---

https://datasciencepublicpolicy.org/wp-content/uploads/2018/05/metrictree-1200x750.png

¿Se pueden satisfacer simultaneamente más de una definición de *fairness*?

P. Garg, J. Villasenor and V. Foggo, "Fairness Metrics: A Comparative Analysis," 2020 IEEE International Conference on Big Data (Big Data), Atlanta, GA, USA, 2020, pp. 3662-3666, 10.1109/BigData50022.2020.9378025.

¿Es posible crear un modelo que satisfaga todas las definiciones de equidad?

- La respuesta es que eso no es posible, las definiciones vistas arriba codifican relaciones entre distintas métricas y estos valores a veces entran en conflicto.

- COMPAS
  - Northpointe: calibración (que defiende Northpointe)
  - Propublica: la igualdad en tasas de falsos positivos/negativos
  - tasas base de reincidencia difieren entre grupos.

➡ imposible satisfacer simultáneamente

Relación entre Equal Odds, Predictive Parity y Statistical Parity

---

- En este documento pueden encontrar algunos analisis de la relación entre estos criterior.

- Bibliografía para analizar la relación entre los criterios de eqiudad:
  - P. Garg, J. Villasenor and V. Foggo, "Fairness Metrics: A Comparative Analysis," *2020 IEEE International Conference on Big Data (Big Data)*, Atlanta, GA, USA, 2020, pp. 3662-3666, doi: 10.1109/BigData50022.2020.9378025.
  - sección 5.4 del libro Fairness & Algorithmic Decision Making.

Fairness más allá de los clasificadores binarios

Clasificadores multiclase

- En la clasificación binaria, los resultados se limitan a 0 y 1, pero en algunos casos se necesitan más de dos clases de salida.
- En la clasificación multiclase, la salida $f(x)$ pertenece a un conjunto de resultados discretos y mutuamente excluyentes, como 1, 2,..., N.
- También permitimos que el atributo protegido A (p. ej., etnicidad) pertenezca a un conjunto de grupos discretos y mutuamente excluyentes, como 1, 2,..., M.
- En el entorno multiclase, tenemos una matriz $N \times N$, con entrada i,j siendo el número de veces que hemos predicho la clase i y la clase verdadera es j.

Predicted Class \ True Class	Apple	Orange	Mango
Apple	7	8	9
Orange	1	2	3
Mango	3	2	1

Ejemplo: Multiclass Statistical Parity

- Matriz de frecuencias: FM_{ai} = P(Ypred = i, A=a)
- Un clasificador multiclase satisface la paridad demográfica si las probabilidades condicionales de clase del grupo protegido son iguales en todos los grupos.
- En las ecuaciones, $FM_a = FM_b$ para dos grupos cualesquiera, a y b..

Ejemplo: Multiclass Statistical Parity

1. Comenzamos calculando la matriz de frecuencias.
2. Recordemos que cada fila es una distribución (la asignación de un grupo a las clases).
3. Normalmente, necesitaremos una forma de comparar estas matrices fila por fila.
4. En el contexto más general, podemos usar cualquier distancia en las distribuciones.
5. En la práctica, usamos la distancia de variación total.
    1. $d(a,b) = \frac{1}{2} \sum_i |FM_{ai} - FM_{bi}|$
6. Necesitamos una forma de agregar estas puntuaciones.
7. Normalmente, usamos un máximo para tener una idea del peor escenario posible.

También podemos usar un promedio o un promedio ponderado, donde las ponderaciones son la importancia de que cada par de grupos reciba un tratamiento similar.

Ejemplo: Multiclass Statistical Parity

- Consideremos el siguiente caso M = 3 grupos (A,B,C) and N =3 classes (0,1,2).
- Datos: $\begin{bmatrix} A & A & A & A & B & B & B & B & C & C \\ 0 & 1 & 2 & 0 & 1 & 2 & 0 & 1 & 2 & 0 \end{bmatrix}$
- Calculamos la matriz de frecuencias:

  Recordando FM_{ai} = P(Ypred = i, A=a)

$$FM = \begin{bmatrix} 0.5 & 0.25 & 0.25 \\ 0.25 & 0.5 & 0.25 \\ 0.5 & 0 & 0.5 \end{bmatrix}$$

Ejemplo: Multiclass Statistical Parity

- Consideremos el siguiente caso M = 3 grupos (A,B,C) and N =3 classes 0,1,2}.
- Datos:

$$\begin{bmatrix} A & A & A & A & B & B & B & B & C & C \\ 0 & 1 & 2 & 0 & 1 & 2 & 0 & 1 & 2 & 0 \end{bmatrix}$$

- Calculamos la matriz de frecuencias:

Recordando FM_{ai} = P(Ypred = i, A=a)

$$FM = \begin{bmatrix} 0.5 & 0.25 & 0.25 \\ 0.25 & 0.5 & 0.25 \\ 0.5 & 0 & 0.5 \end{bmatrix}$$

Ejemplo: Multiclass Statistical Parity

- Consideremos el siguiente caso M = 3 grupos(A,B,C) and N =3 classes 0,1,2}.
- Datos:

$$\begin{bmatrix} A & A & A & A & B & B & B & B & C & C \\ 0 & 1 & 2 & 0 & 1 & 2 & 0 & 1 & 2 & 0 \end{bmatrix}$$

- Calculamos la matriz de frecuencias:

Recordando FM_{ai} = P(Ypred = i, A=a)

$$FM = \begin{array}{c} \\ \\ \\ \text{Clase} \end{array} \begin{array}{c} \begin{bmatrix} 0.5 & 0.25 & 0.25 \\ 0.25 & 0.5 & 0.25 \\ 0.5 & 0 & 0.5 \end{bmatrix} \\ \begin{array}{ccc} 0 & 1 & 2 \end{array} \end{array} \begin{array}{c} \text{Grupo} \\ A \\ B \\ C \\ \\ \end{array}$$

Ejemplo: Multiclass Statistical Parity

- Calculamos la distancia entre las filas, usando d(a,b) =½ $\sum_i |FM_{ai} - FM_{bi}|$:
  -
  - d(fila1, fila2) = 0.5(|0.5 −0.25|+|0.25-0.5|+|0.25 −0.25|) = 0.25
  - d(fila2, fila3) = 0.5(|0.25 −0.5|+|0.5-0|+||0.25 −0.5) = 0.5
  - d(fila1, fila3) = 0.5(|0.5 −0.5|+|0.25 −0|+|0.25 −0.5|) = 0.25

- Si consideramos el **máximo**: max(0.5, 0.25, 0.25) = 0.5
- Si consideramos la **media**: mean(0.5, 0.25, 0.25)=1/3

Regresión equitativa

- **Motivación:** Los tomadores de decisiones prefieren puntajes (ej. riesgo de reincidencia, GPA esperado) porque preservan su autonomía profesional.
- **Problema:** ¿Cómo garantizar equidad cuando el resultado no es un simple "sí" o "no", sino un valor real en el rango ?

En lo que sigue:

- **Datos:** (X,A,Y), donde A es el atributo protegido.
- **Predictores:** Funciones $f:X,A \to \mathbb{R}$.
- **Función de Pérdida (ℓ):** Debe ser **1-Lipschitz**. Ejemplo: Error cuadrático
- **Importancia:** La continuidad Lipschitz asegura que pequeños cambios en la predicción no causen saltos extremos en el error, permitiendo una optimización estable.

Fuente: Agarwal, A., Dudik, M. & Wu, Z.S.. (2019). Fair Regression: Quantitative Definitions and Reduction-Based Algorithms. https://proceedings.mlr.press/v97/agarwal19d.html.

Regresión Equitativa: Paridad estadística

- **Paridad estadística en regresión:** La predicción $f(X)$ debe ser estadísticamente independiente del atributo protegido A.

- **Caracterización por CDF:** $P[f(X) \leq z \mid A = a] = P[f(X) \leq z]$ para todo $a \in A$, $z \in \mathbb{R}$.

Fuente: Agarwal, A., Dudik, M. & Wu, Z.S.. (2019). Fair Regression: Quantitative Definitions and Reduction-Based Algorithms. https://proceedings.mlr.press/v97/agarwal19d.html.

Regresión Equitativa: Pérdida Grupal Acotada

- **Definición:** El error promedio para cada grupo debe ser menor a un nivel ζ.
- **Fórmula:** $E[\ell(Y,f(X)) \mid A=a] \leq \zeta$.
  - Representa la **calidad de servicio** promedio para el grupo a.
  - No busca igualdad de error, sino un **mínimo aceptable** para todos.

Fuente: Agarwal, A., Dudik, M. & Wu, Z.S.. (2019). Fair Regression: Quantitative Definitions and Reduction-Based Algorithms. https://proceedings.mlr.press/v97/agarwal19d.html.

Otros casos

- Regresión:
  - Berk et al, 2017, A Convex Framework for Fair Regression https://arxiv.org/pdf/1706.02409.pdf
  - Dwork et al. 2012, Fairness Through Awareness https:// arxiv.org/abs/1104.3913
- Clustering:
  - Chhabra, Anshuman, Karina Masalkovaitė, and Prasant Mohapatra. "An overview of fairness in clustering." IEEE Access (2021)
- Recomendadores

Trabajo Práctico

- Leer en conjuto el enunciado, ir aclarado las consultas.
- Lineamientos de las slides para la primera presentación.
- Trabajaremos en los ejercicios 1, 2 y 3.

Ejemplos de algunas diapositivas para el trabajo práctico

Analizar proyectos basados en datos

---

objetivos del proyecto
(y sus métricas)
- acierto?
- equidad?

acciones

datos

análisis de datos
- calidad
- hipótesis sobre potenciales falencias

Analizar con perspectiva de equidad:

comportamientos discriminatorios que producen daños

Escenarios de daño

- grupo protegido / variable protegida
- variable objetivo de predicción
- qué errores de predicción son más graves: falsos positivos, falsos negativos, sus diferencias

Ejemplo: predicción de riesgo de reincidencia

---

objetivos del proyecto:

- evitar que una persona cometa un delito
- preservar el derecho a la libertad (tercer grado)

acciones

- predecir el nivel de riesgo de reincidencia

datos

histórico de condenas

análisis de datos

- poblaciones desiguales
- sesgo histórico

Escenario de daño

---

variable protegida: **raza**

grupo protegido: **negros**

grupo privilegiado: **blancos**

variable objetivo: **riesgo**

errores más graves: **falsos positivos**

Próxima clase:
auditoría, presentación avance del TP y consultas

Referencias

- Barocas, S., Hardt, M., & Narayanan, A. (2023). Fairness and Machine Learning: Limitations and Opportunities. MIT Press.
- Castelnovo, A., Crupi, R., Greco, G., Regoli, D., Penco, I. G., & Cosentini, A. C. (2022). A clarification of the nuances in the fairness metrics landscape. Scientific Reports, 12(1), 4209. https://doi.org/10.1038/s41598-022-07939-1
- Leslie, D., Rincón, C., Briggs, M., Perini, A., Jayadeva, S., Borda, A., Bennett, SJ. Burr, C., Aitken, M., Katell, M., Fischer, C., Wong, J., and Kherroubi Garcia, I. (2023). AI Fairness in Practice. The Alan Turing Institute.
- Verma, S. and Rubin, J. 2018. Fairness definitions explained. In Proceedings of the International Workshop on Software Fairness (FairWare '18). Association for Computing Machinery, New York, NY, USA, 1–7. https://doi.org/10.1145/3194770.3194776
- Frenkel, A..Fairness and Algorithmic Decision Making- Lecture Notes for UCSD course DSC 167.

Solución del ejercicio

Ejemplo de interpetación I

---

1) Sistema de IA para diagnóstico médico

   Se está desarrollando un sistema de IA para ayudar a los médicos a analizar las señales del electrocardiograma. Este sistema ayudará a los médicos a diagnosticar afecciones cardíacas. Debido a las disparidades históricas y estructurales, algunos grupos demográficos son más propensos a experimentar múltiples factores que contribuyen a la insuficiencia cardíaca. Esta combinación de la compleja gama de factores de riesgo y la vinculación de algunos de estos factores con los grupos demográficos desfavorecidos aumenta las posibilidades de que el sistema de IA de diagnóstico pueda funcionar mejor para algunos grupos que para otros. El equipo del proyecto debe definir su enfoque de *fairness* basada en métricas.

Ejemplo de interpetación I

En este contexto:

- ¿Qué tipo de daños podría ocasionar la utilización de este sistema si fallara?
- Analizar TP, FP, TN, FN. Cuáles son peores?

Ejemplo de interpetación I

– – –

- **Demographic parity**:

$$P(\hat{Y} = 1|A = a) = P(\hat{Y} = 1|A = b) \quad \forall \; a, b \in A$$

El sistema de IA puede ofrecer la misma tasa de diagnósticos positivos en todos los grupos demográficos. Esto significa que las predicciones positivas serían equivalente en los grupos desfavorecidos y favorecidos.

Ejemplo de interpetación I

- **Equalized odds**:

$$P(\hat{Y} = 1|A = a, Y = y) = P(\hat{Y} = 1|A = b, Y = y) \quad \forall\ a, b \in A, y \in \{0,1\}$$

El sistema de IA puede ofrecer las mismas tasas de diagnósticos precisos y diagnósticos inexactos en todos los grupos demográficos. Esto significa que los grupos demográficos desfavorecidos y favorecidos tendrían la misma probabilidad de recibir predicciones positivas verdaderas y falsas.

Ejemplo de interpetación I

- **Equal opportunity**:

$$P(\hat{Y} = 0|G = a, Y = 1) = P(\hat{Y} = 0|G = b, Y = 1) \quad \forall\ a, b \in A$$

El sistema de IA puede ofrecer la misma tasa de diagnósticos correctos en todos los grupos demográficos. Esto significa que la precisión del modelo para las predicciones positivas sería equivalente en los grupos desfavorecidos y favorecidos

Ejemplo de interpetación I

- **Predictive parity**:

$$P(Y = 1|A = a, \hat{Y} = 1) = P(Y = 1| A = b, \hat{Y} = 1) \quad \forall \ a, b \in A$$

Los grupos protegidos y los no protegidos tienen igual probabilidad de que las predicciones positivas pertenezca realmente a la clase positiva. Es decir, la probabilidad de tener predicciones de diagnostico positivo que realmente lo son es la misma para los grupos analizados.

Ejemplo de interpetación I

- **False Positive Rate**:

$$P(\hat{Y} = 1|A = a, Y = 0) = P(\hat{Y} = 1|A = b, Y = 0) \quad \forall\ a, b \in A$$

Los grupos protegidos y los no protegidos tienen igual probabilidad de que las predicciones positivas pertenezcan a la clase negativa. Es decir, la probabilidad de tener predicciones de diagnostico positivo erroneas es la misma para los grupos analizados.

Ejercicio: Armar declaración de posición

Para el caso analizado previamente, completar la declaración de posición de fairness:

Definición	Nuestro equipo eligio _____ como definición de *fairness*.
Justificación	Elegimos esta métrica porque _____.
Resultado	Remasterizar el modelo hacia esta medida garantizará que _____ .