# Fairness en Machine Learning

*Fairness*

# Agenda

1. Evaluación de modelos
2. Criterios de Fairness
   a. Definiciones preliminares:
   b. apuntando a Group Fairness

# Recomendaciones

https://data-feminism.mitpress.mit.edu/bienvenida

# Popurrí

---

https://www.dair-institute.org/

https://sistemaspublicos.tech/regulacion-sobre-ia-en-america-latina/

# Fechas importantes

---

- Primer parcial: 30/04
- Recuperatorio del primer parcial: 14/05
- Segundo parcial: 04/06
- Recuperatorio del segundo parcial: 18/06

# Evaluación de modelos

Basado en el curso “Evaluación responsable de sistemas de aprendizaje automático” de la Dra. Luciana Ferrer

# Importancia de la evaluación de sistemas basados en aprendizaje automático

- ¿Para qué evaluamos los sistemas basados en aprendizaje automático?

- Objetivo de una evaluación: cómo va a repercutir el uso de ese sistema al usuario final en realidad.

# ¿Dónde podemos fallar al evaluar?

---

# ¿Dónde podemos fallar al evaluar?

---

- el conjunto de datos

# ¿Dónde podemos fallar al evaluar?

---

- el conjunto de datos
  - su evaluamos en datos que usamos para entrenar o desarrollar el modelo → los resultados serán óptimos y tramposos.
  - si evaluamos en datos que no son representativos del caso de uso → estaremos midiendo en algo que no refleja el rendimiento real en la práctica

# ¿Dónde podemos fallar al evaluar?

---

- el conjunto de datos
  - su evaluamos en datos que usamos para entrenar o desarrollar el modelo → los resultados serán óptimos y tramposos.
  - si evaluamos en datos que no son representativos del caso de uso → estaremos midiendo en algo que no refleja el rendimiento real en la práctica
- la elección de las métricas utilizadas para la evaluación y el reporte

# ¿Dónde podemos fallar al evaluar?

---

- el conjunto de datos
  - su evaluamos en datos que usamos para entrenar o desarrollar el modelo → los resultados serán óptimos y tramposos.
  - si evaluamos en datos que no son representativos del caso de uso → estaremos midiendo en algo que no refleja el rendimiento real en la práctica
- la elección de las métricas utilizadas para la evaluación y el reporte
  - si la elección de métricas incorrectas → estaremos midiendo en algo que no refleja el rendimiento real en la práctica
  - Si se pierde de vista que hay grupos con distinto comportamiento → podemos estar ignorando que el sistema es sesgado o injusto.

# ¿Dónde podemos fallar al evaluar?

---

- el conjunto de datos
  - su evaluamos en datos que usamos para entrenar o desarrollar el modelo → los resultados serán óptimos y tramposos.
  - si evaluamos en datos que no son representativos del caso de uso → estaremos midiendo en algo que no refleja el rendimiento real en la práctica
- la elección de las métricas utilizadas para la evaluación y el reporte
  - si la elección de métricas incorrectas → estaremos midiendo en algo que no refleja el rendimiento real en la práctica
  - Si se pierde de vista que hay grupos con distinto comportamiento → podemos estar ignorando que el sistema es sesgado o injusto.
- poca o nula significancia estadística

# Consecuencias de las evaluaciones

---

- La evaluación **incorrecta** puede resultar en un mal uso del sistema, hay que pensar en la gravedad de esto. Si funciona:
  - peor de lo que pensamos → ¿deberíamos usarlo?
  - peor sobre ciertos grupos → ¿deberíamos usarlo?

- La evaluación **correcta** y detallada de los sistemas nos permite tomar buenas decisiones:
  - si el rendimiento es insuficiente, volvemos a la etapa de desarrollo
  - si el sistema es injusto trataremos de resolverlo o, al menos, ser consciente.

# Consecuencias de las evaluaciones

---

- La evaluación **incorrecta** puede resultar en un mal uso del sistema, hay que pensar en la gravedad de esto. Si funciona:
  - peor de lo que pensamos → ¿deberíamos usarlo?
  - peor sobre ciertos grupos → ¿deberíamos usarlo?

- La evaluación **correcta** y detallada de los sistemas nos permite tomar buenas decisiones:
  - si el rendimiento es insuficiente, volvemos a la etapa de desarrollo
  - si el sistema es injusto trataremos de resolverlo.

# Ejemplo

---

1. Predicción de embarazos adolescentes en Salta. 2018.
   a. ¿Qué querían resolver?
   b. Problemas hallados:
      i. **Resultados artificialmente sobredimensionados**: usaron datos de entrenamiento en la evaluación
      ii. **Datos posiblemente sesgados**: se tomaba como verdadero lo que decía la adolescentepero al ser un tema sensible no siempre es la verdad.
      **iii.** **Datos inadecuados**: el objetivo del problema era predecir a futuro pero los datos para entrenar eran si está o estuvo embarazada. Los datos de entrada debieron ser las características de meses o años previos.

https://liaa.dc.uba.ar/es/sobre-la-prediccion-automatica-de-embarazos-adolescentes/

# Problemas habituales en la evaluación de sistemas en la actualidad

- Overfiteo comunitario
- Selección tramposa de umbrales
- Perder de vista las minorías

# Fairness en Machine Learning

Criterios de *fairness*

# Objetivos

1. ¿A qué nos referimos con que un modelo basado en aprendizaje automático sea *fair*?
   a. Individual *fairness*
   **b. Group *fairness***

# Definiciones previas

---

- **Atributo protegido** / **atributo sensible**:  es una característica personal protegida por ley contra la discriminación. Estos atributos incluyen la edad, el género, la raza, la religión y situación socioeconómica.

- **Proxy**: son atributos fuertemente correlacionados con atributos protegidos.
  - Por ejemplo, código postal (fuertemente correlacionada con situación socioeconómica).

# Comentarios respecto a la notación

---

**X**

| | Sex | Age | Job | Housing | Saving accounts | Checking account | Credit amount | Duration | Purpose | Risk |
|---|---|---|---|---|---|---|---|---|---|---|
| 0 | male | 67 | 2 | own | NaN | little | 1169 | 6 | radio/TV | good |
| 1 | female | 22 | 2 | own | little | moderate | 5951 | 48 | radio/TV | bad |

⇩ ⇩

**A** **Y**

X: atributos sin considerar el atributo protegido
A: la variable categórica para el atributo protegido
Y: el resultado de interés
Ŷ: predicción del modelo

# Comentarios respecto a la notación

---

**X**

| | Sex | Age | Job | Housing | Saving accounts | Checking account | Credit amount | Duration | Purpose | Risk |
|---|---|---|---|---|---|---|---|---|---|---|
| 0 | male | 67 | 2 | own | NaN | little | 1169 | 6 | radio/TV | good |
| 1 | female | 22 | 2 | own | little | moderate | 5951 | 48 | radio/TV | bad |

⇩ ⇩

**A** **Y**

X = [Age, jobs, housing, saving_accounts, checking_accounts, duration, purpose]
A = Sex
Y = Risk

# Observaciones

---

Performance y *fairness*

- Performance malas pueden resultar en modelos injustos
- Modelos con buenas perfomance no necesariamente son los más *fair*

# ¿A qué nos referimos con que un modelo basado en ML sea *fair*?

# Definición y medición de la **equidad**

---

Existen diversas maneras de definir y medir la equidad de un modelo:

- **Equidad procesal**
- **Equidad de resultados**
- **Equidad individual**
- **Equidad grupal**

The Turing Institute - Technical interpretation of fairness/bias

# Definición y medición de la **equidad**

---

Existen diversas maneras de definir y medir la equidad de un modelo:

- **Equidad procesal:** • ¿El modelo trata a las personas sin discriminación ni prejuicios?
- **Equidad de resultados**: • ¿Los resultados del modelo son justos?
- **Equidad individual**: • ¿El modelo trata de manera similar a personas con características similares?
- **Equidad grupal**: • ¿El modelo trata de manera justa a los diferentes grupos?

The Turing Institute - Technical interpretation of fairness/bias

# Individual *fairness*

# Definición de Individual *fairness*

---

Tratar a individuos **similares** de manera **similar**

# Definición de Individual *fairness*

---

Distribución similar de los resultados

Tratar a individuos **similares** de manera **similar**

dominio de los atributos

# Definición de Individual *fairness*

---

Distribución similar de los resultados

Tratar a individuos **similares** de manera **similar**

dominio de los atributos

**¿En qué contextos podría resultar de utilidad este criterio de fairness?**

# Individual fairness: 1. Discriminación causal

---

- Para decidir si un clasificados satisface la definición de **discriminación causal** se analiza si para dos sujetos cualesquiera con exactamente los mismos atributos X se produce la misma clasificación.

- Ejemplo:

  ¿un solicitante hombre y una solicitante mujer que tienen los mismos atributos X se les asignará a ambos la misma  puntuación crediticia?

# Individual fairness: 2. *Fairness through awareness*

---

- la distancia entre la predicción para dos individuos cualesquiera es, como máximo, la distancia entre ellos.

  Es decir, si:

$$dist_{out}(Y_1,Y_2) \leq dist_{in}(X_1,X_2)$$

# Individual fairness: 2. *Fairness through awareness* ---

- la distancia entre la predicción para dos individuos cualesquiera es, como máximo, la distancia entre ellos.

- Ejemplos de métricas:

| Atributos | Resultados |
|---|---|
| $dist_1(Xi,Xj) = \begin{cases} 0 & \text{si } X^i = X^j \\ 1 & \text{si } X^i \neq X^j \end{cases}$ | $dist_2(Yi,Yj) = \begin{cases} 0 & \text{si } Y^i = Y^j \\ 1 & \text{si } Y^i \neq Y^j \end{cases}$ |

# Individual fairness: 2. *Fairness through awareness*

- Ejemplos de métricas:

| Atributos | Resultados |
|---|---|
| dist1(Xi,Xj) = 0 si Xi = Xj<br>1 si Xi ≠ Xj | dist2(Yi,Yj) = 0 si Yi = Yj<br>1 si Yi ≠ Yj |

| ID | Atributo 1 | Atributo 2 | Atributo protegido | Output |
|---|---|---|---|---|
| 0 | 1 | 2 | a | 1 |
| 1 | 1 | 2 | b | 1 |
| 2 | 1 | 2 | a | 0 |

$$dist_{out}(Y_1,Y_2) \leq dist_{in}(X_1,X_2)$$

Caso id=0 e id=1:

$$dist_{out}(Y_0,Y_1) \leq dist_{in}(X_0,X_1)=$$
$$dist_{out}(1,1) \leq dist_{in}((1,2),(1,2))=$$

$0 \leq 0$ ✅

# Individual fairness: 2. *Fairness through awareness*

- Ejemplos de métricas:

| Atributos | Resultados |
|---|---|
| dist1(Xi,Xj) = 0 si Xi = Xj<br>1 si Xi ≠ Xj | dist2(Yi,Yj) = 0 si Yi = Yj<br>1 si Yi ≠ Yj |

| ID | Atributo 1 | Atributo 2 | Atributo protegido | Output |
|---|---|---|---|---|
| 0 | 1 | 2 | a | 1 |
| 1 | 1 | 2 | b | 1 |
| 2 | 1 | 2 | a | 0 |

$$dist_{out}(Y_1,Y_2) \leq dist_{in}(X_1,X_2)$$

Caso id=1 e id=2:

$$dist_{out}(Y_1,Y_2) \leq dist_{in}(X_1,X_2)=$$
$$dist_{out}(1,0) \leq dist_{in}((1,2),(1,2))=$$

$$1 \leq 0$$ ❌

# Individual fairness: *fairness through unawareness* – – –

- Para evitar el sesgo al no incluir explícitamente atributos protegidos en el modelado

- Ejemplo:
  - entrenamos el modelo de regresión logística sin utilizar ningún} atributo derivado del atributo de género.
  - Luego, para cada solicitante en el conjunto de prueba, generamos un individuo idéntico del género opuesto y comparamos la clasificación prevista para estos dos solicitantes.
  - Los resultados muestran que la clasificación para todos los individuos "idénticos" que solo difieren en género fue idéntica.
  - Por lo tanto, consideramos que el clasificador satisface esta definición.

# Individual fairness: *fairness through unawareness*

---

**Problema**: Otros atributos podrían estar correlacionados con los atributos sensibles.

**Ejemplo:** COMPAS

- No usa explícitamente información acerca de si la persona es negra o blanca.
- Problema: Atributos correlacionadas (pobreza, desempleo y marginación social
- Uno de los desarrolladores del sistema afirmó que es difícil construir una puntuación que no incluya elementos que puedan correlacionarse con la raza.
- «Si se omiten estos elementos en la evaluación de riesgos, la precisión disminuye».

# Cheat sheet (ojo *individual fairness*)

---

## Cheat Sheet: Types of Statistical Fairness

By Samara Trilling and Madison Jacobs

**RELEVANT DEFINITIONS**

**Protected Group:** a group against which it is illegal to discriminate. For example, the Fair Housing Act prohibits discrimination on the basis of seven protected attributes: race, color, religion, national origin, sex, disability, and familial status. The Equal Credit Opportunity Act prohibits discrimination based on these plus three more: marital status, age, or because someone receives public assistance. Individual states may define additional protected groups; for example, New York State prohibits discrimination on the basis of sexual orientation and gender identity or expression.

Why does picking a definition matter? If you choose the wrong definition of fairness, you may actually increase discrimination against the group you aim to help.

| TYPE OF FAIRNESS | TECHNICAL DEFINITION | WHAT IT MEANS IN LENDING | PROS | CONS |
|---|---|---|---|---|
| **No Fairness** | *Also known as Max Profit* Have no fairness requirement at all. | You can use any data you want, including protected characteristics. The goal is to maximize profit. | Easy; makes money. | Violates disparate treatment and disparate impact standards. |
| **Fairness Through** | *Also known as race / gender blindness* | Don't give any information about race, gender, or other 'protected characteristics' of | Easy to implement and check; may satisfy disparate | Can violate disparate impact standard. If race/gender can be deduced from a |

# Referencias


- Dwork, C., Moritz Hardt, Toniann Pitassi, Omer Reingold, and Richard Zemel. 2012. Fairness through awareness. In Proceedings of the 3rd Innovations in Theoretical Computer Science Conference (ITCS '12). Association for Computing Machinery, New York, NY, USA, 214–226. https://doi.org/10.1145/2090236.2090255
- Gao, J., Chou, B., McCaw, Z. R., Thurston, H., Varghese, P., Hong, C., & Gronsbell, J. (2024). What is Fair? Defining Fairness in Machine Learning for Health. arXiv preprint arXiv:2406.09307.
- Gao, J., Chou, B., McCaw, Z. R., Thurston, H., Varghese, P., Hong, C., & Gronsbell, J.(2024) A tutorial on fairness in machine learning in healthcare. https://arxiv.org/html/2406.09307v1
- Verma, S. and Rubin, J. 2018. Fairness definitions explained. In Proceedings of the International Workshop on Software Fairness (FairWare '18). Association for Computing Machinery, New York, NY, USA, 1–7. https://doi.org/10.1145/3194770.3194776

# Definiciones preliminares: apuntando a Group Fairness

# Matriz de confusión - Caso binario

---

| | | **Realidad** | |
|---|---|---|---|
| | | Positivo | Negativo |
| **Predicción** | Positivo | TP | FP |
| | Negativo | FN | TN |

# Matriz de confusión

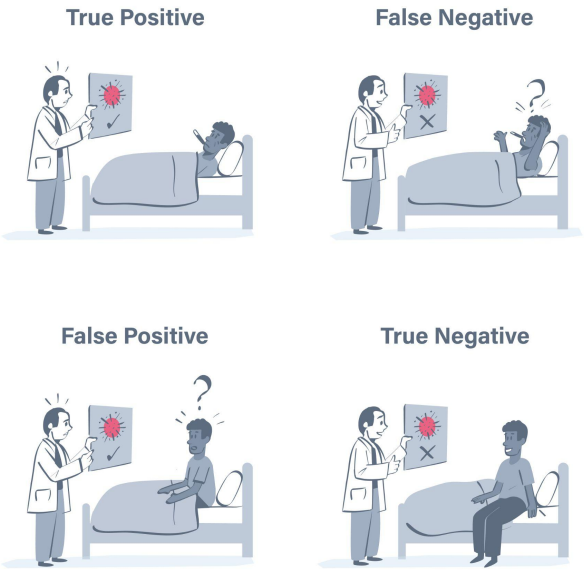


Caso **positivo**: está enfermo

Caso **negativo**: no está enfermo

Fuente: https://alan-turing-institute.github.io/turing-commons/skills-tracks/rri/rri-203-3/#statistical-fairness-issue-1-class-imbalance-and-accuracy

# Ejercicio: calcular la matriz de confusión

¿Es un chihuahua o una galletita?

# Ejercicio: calcular la matriz de confusión

¿Es un chihuahua o una galletita?

Pero..

# Ejercicio: calcular la matriz de confusión

---

Datos

modelo

Predicción

✅
✅
❌
❌
✅
✅
✅

**Positivo**: es un chiuaua

**Negativo**: no es un chihuahua, en este contexto, es galletita.

# Ejercicio: calcular la matriz de confusión

---

Datos

modelo

Predicción

✅
✅
❌
❌
✅
✅
✅

| | | *Realidad* | |
|---|---|---|---|
| | | Positivo | Negativo |
| *Predicción* | Positivo | | |
| | Negativo | | |

# Ejercicio: calcular la matriz de confusión

| y real | y predicho |
|---|---|
| 1 | 1 |
| 1 | 1 |
| 1 | 0 |
| 0 | 1 |
| 0 | 1 |
| 0 | 1 |
| 0 | 0 |
| 0 | 0 |
| 0 | 0 |
| 0 | 0 |

| | | Realidad | |
|---|---|---|---|
| | | Positivo | Negativo |
| Predicción | Positivo | TP | FP |
| | Negativo | FN | TN |

| | |
|---|---|
| | |
| | |

# Ejercicio

Duración: 10 minutos en sala de grupos

1. Nos dividiremos en los grupos definidos para el Trabajo Práctico.
2. Cada grupo interpretará qué significan los TP, TN. FP y FN.
3. Volvemos a la sala principal y cada grupo compartirá sus interpretaciones.

Link al enunciado:
http://tiny.cc/equidad_clase3
(ejercicio 1)

# Breve repaso de algunas nociones de probabilidad

# Repaso probabilidad I

- **Espacio muestral:** el conjunto de los posibles resultados de un experimentos. Suele notarse con $\Omega$ omega. Veamos unos ejemplos:
    - si estamos arrojando un dado, el espacio muestral para este experimento sería:

      $$\Omega = \{1, 2, 3, 4, 5, 6\} = \{i \in N, 1 \leq i \leq 6\}$$

    - Si estamos arrojando una moneda, podrıa ser

      $$\Omega = \{ca, cr\}.$$

    - Si son dos dados, tenemos

      $$\Omega = \{(1, 1), (1, 2), \ldots, (6, 6)\} = \{(i, j) : i, j \in N, 1 \leq i \leq 6, 1 \leq j \leq 6\}$$

      $$= \{1, 2, 3, 4, 5, 6\} \times \{1, 2, 3, 4, 5, 6\}.$$

    - Si arrojamos una moneda hasta que sale cara, tenemos

      $$\Omega = \{(ca), (cr,ca), (cr,cr,ca), \ldots\}$$

# Repaso probabilidad II

- **Evento**: podemos pensarlo como un subconjunto del espacio muestral Tenemos las siguientes particularidades:
  - $\Omega$ es un evento, conocido como el evento cierto o seguro.
  - $\varnothing$ es el evento vac ío o imposible.
  - Si A y B son eventos, $A \cup B$ es el evento unión y ocurre cuando pasa cualquiera de los dos eventos, o los dos.
  - Si A y B son eventos, $A \cap B$ es el evento interseccio ń y ocurre cuando pasan ambos eventos a la vez.
  - Ac es el evento complementario y ocurre cuando no pasa A.
  - $A - B = A \cap Bc$ es el evento diferencia y ocurre cuando pasa A pero no pasa B.

- Ejemplo: en el experimento de arrojar un dado, donde el espacio muestral es $\Omega = \{1, 2, 3, 4, 5, 6\}$, , podemos considerar A = el dado salió  ́par = {2, 4, 6}.

# Repaso probabilidad III

---

La **probabilidad** es una función que dado un evento A devuelve un nu ḿero $P(A) \in [0, 1]$.

Los axiomas fundamentales son

1. $P(A) \in [0, 1]$.
2. $P(\Omega) = 1$.
3. $P(\varnothing) = 0$.
4. (aditividad) Si A y B son dos eventos disjuntos, es decir, con intersección ń nula, entonces $P(A \cup B) = P(A) + P(B)$. En rigor de verdad, el u lt̂imo resultado no es formalmente un ”axioma”, un axioma más correcto ser ıá el siguiente:

   4A* (σ-aditividad). Si A1, A2, . . . es una sucesión de eventos disjuntos de a pares, luego $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$. Se puede probar, usando A3 y A4*, el axioma A4, aunque no al reve ś. Omitiremos estos detalles para no hacer más f̂arragosa la lectura. Algunos resultados. De los axiomas se deducen estas propiedades. Las demostraciones son optativas pero seguirlas marcar ıá un buen punto para ver de entender la correcta comprensión d́e los axiomas.

# Repaso probabilidad IV

---

**Probabilidad condicional**: queremos calcular la probabilidad de que ocurra un evento A sabiendo que ocurrió (o que va a ocurrir) el evento B. Es decir, no hay azar impuesto sobre el evento B, ya sabemos que va a pasar o que paso .´Es informacion que conocemos, que B ocurrío, y nos preguntamos cua l´es la probabilidad de que ocurra entonces A.

Formalmente, notaremos esta situación como P(A|B). La definición formal es la siguiente:

**Dado un evento B tal que P(B) > 0, se define** $$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

Queremos calcular la probabilidad de A, tomamos todos los elementos de A que también están en B (eso es P(A ∩ B)) y renormalizamos considerando que ahora todo el espacio muestral pasar ía a ser, en algún sentido, el conjunto B (eso es dividir por P(B)).

# Repaso probabilidad IV

Probabilidad condicional. Ejemplo:

1. Se arroja un dado de seis caras y nos dicen que salió un número par. ¿Cuál es la probabilidad de haber obtenido un 4?

   Rta: nos piden P(obtener 4|dado es par).

   P(obtener 4|dado es par) = P(obtener 4∩dado es par) / P(dado es par)

   Obs:

   {1, 2, 3, 4, 5, 6}

   {1, **2**, 3, **4**, 5, **6**} => P(obtener par) = 3/6 = ½

   {1, 2, 3, **4**, 5, 6} => P(obtener 4) = 1/6

   Entonces, P(obtener 4|dado es par) = P(obtener 4∩dado es par) / P(dado es par) = ⅓

# Probabilidad condicional - Ejemplo I

---

## Recall o True Positive Rate

**Problema:** Sabiendo que un paciente **está enfermo (Y=1)**, ¿cuál es la probabilidad de que el modelo lo **detecte ($\hat{Y}$=1)**?.

- **Cálculo:**

$$P(\hat{Y}=1 \mid Y=1) = P(\hat{Y}=1 \cap Y=1)/P(Y=1).$$

- **Equivalencia en Matriz:** TP/(TP+FN).

# Probabilidad condicional - Ejemplo II

---

## Precisión

**Problema:** Si el modelo **predice positivo (Ŷ=1)**, ¿cuál es la probabilidad de que el paciente **realmente esté enfermo (Y=1)**?.

- **Cálculo:**

$$P(Y=1 \mid \hat{Y}=1) = P(Y=1 \cap \hat{Y}=1)/\{P(\hat{Y}=1).$$

- **Equivalencia en Matriz:** TP/TP+FP.
  - *Diferencia clave:* En el Recall condicionamos por la **Realidad**, en la Precisión condicionamos por la **Predicción**.

# Repaso probabilidad V

---

A partir de que $P(A|B) = P(A \cap B) / P(B)$ es inmediato despejar que

$$P(A \cap B) = P(A|B)P(B).$$

En esto sencillamente consiste la regla multiplicativa, permite expresar una probabilidad conjunta (una intersección) a partir de una probabilidad condicional.

# Repaso probabilidad VI

– – –

- Decidimos que dos eventos A y B son **independientes** si:

$$P(A \cap B) = P(A)P(B).$$

  Se nota: $A \perp B$.

- Supongamos que A y B son independientes, y supongamos también que $P(B) > 0$. Entonces, notemos que:

$$P(A|B) = P(A \cap B) \ / \ P(B) = P(A)P(B) \ / \ P(B) = P(A).$$

  **Luego, bajo independencia, $P(A|B) = P(A)$.**

  O sea, cuando los dos eventos son independientes, el **tener informaciión a priori sobre uno de ellos no altera la probabilidad del otro evento.**

# Independencia - Ejemplo

---

- En el criterio de  Equidad denominado **Demographic Parity**, busca que la predicción $\hat{Y}$ sea independiente del atributo sensible A.
  - Esto se cumple si: $P(\hat{Y}=1 \mid A=a) = P(\hat{Y}=1 \mid A=b)$.

    La probabilidad de recibir un crédito debe ser la misma sin importar el género o raza del solicitante.

# Repaso probabilidad VI

---

- una **variable aleatoria** $X$ es, formalmente, una función $X : \Omega \to R$.
- Abusaremos de la notación, diremos por ejemplo que si $A \subset R$, luego $P(X \in A) = P(\{\omega \in \Omega, X(\omega) \in A\})$.

  Ejemplo: si tiramos dos dados y consideramos como $X$ la suma. Entonces, $P(X = 8) = P(\{(2, 6), (3, 5), (4, 4), (5, 3), (6, 2)\}) = 5/36$.

  Definimos la función de probabilidad puntual de una variable aleatoria $X$ a una función $p_X : R \to [0, 1]$ $p_X(x) = P(X = x)$.

# Notación

- Los criterios estadísticos para analizar la equidad por grupo se basan en la distribución conjunta de:
  1. el atributo sensible A,
  2. la variable objetivo Y,
  3. el clasificador $\hat{Y}$ o la puntuación R y, en algunos casos,
  4. los atributos X.

  Esto significa que podemos decidir sin ambigüedades si un criterio se satisface o no al observar la distribución conjunta de estas variables aleatorias.

- Ejemplo: en el caso de COMPAS
  Reexaminamos el caso de las decisiones de libertad condicional. X representa los atributos del dataset COMPAS y los antecedentes penales del acusado, A representa la raza/etnia, Y representa la reincidencia del acusado, y $\hat{Y}$ determina si se le debe denegar (1) o conceder (0) la libertad condicional.

# Notación

- Los criterios estadísticos para analizar la equidad por grupo se basan en la distribución conjunta de:
  1. el  atributo sensible A,
  2. la variable objetivo Y,
  3. el clasificador $\hat{Y}$ o la puntuación R y, en algunos casos,
  4. los atributos X.

     Esto significa que podemos decidir sin ambigüedades si un criterio se satisface o no al observar la distribución conjunta de estas variables aleatorias.

- Ejemplo: en el caso de COMPAS
  Reexaminamos el caso de las decisiones de libertad condicional. Aquí, X representa la encuesta COMPAS y los antecedentes penales del acusado, A representa la raza/etnia, Y representa la reincidencia del acusado, y $\hat{Y}$ determina si se le debe denegar (1) o conceder (0) la libertad condicional.

P($\hat{Y}$= reincidencia| A=afroamericano, Y=reincidencia) ? P($\hat{Y}$= reincidencia| A=no-afroamericano, Y=reincidencia)

# Definición de métricas de evaluación

# Accuracy

| | | Realidad (Y) | |
|---|---|---|---|
| | | Positivo Y= 1 | Negativo Y=0 |
| Predicción Ŷ | Positivo Ŷ = 1 | TP | FP |
| | Negativo Ŷ=0 | FN | TN |

$$(TP+TN)/(TP+FN+FP+TN)$$

- % de las predicciones realizadas correctamente
- ¿Cuándo es apropiado utilizar accuracy?

# Accuracy

https://xkcd.com/1723/

- Para debatir:

  Si tenemos un modelo como el de la izquierda. ¿Nos serviría accuracy como métrica para analizar si es un modelo útil?

# Precisión

| | | Realidad (Y) | |
|---|---|---|---|
| | | Positivo Y= 1 | Negativo Y=0 |
| Predicción $\hat{Y}$ | Positivo $\hat{Y}$ = 1 | TP | FP |
| | Negativo $\hat{Y}$=0 | FN | TN |

$$TP/(TP+FP)$$

# Prevalencia

| | | Realidad (Y) | |
|---|---|---|---|
| | | Positivo Y= 1 | Negativo Y=0 |
| Predicción Ŷ | Positivo Ŷ = 1 | TP | FP |
| | Negativo Ŷ=0 | FN | TN |

$$(TP+FN)/(TP+FP+FN+TN)$$

# True Positive Rate / Sensitivity / Recall

---

| | | Realidad (Y) | |
|---|---|---|---|
| | | Positivo Y= 1 | Negativo Y=0 |
| Predicción $\hat{Y}$ | Positivo $\hat{Y} = 1$ | TP | FP |
| | Negativo $\hat{Y}=0$ | FN | TN |

$$P(\hat{Y}=1 \mid Y=0)$$

# True Positive Rate / Sensitivity / Recall

---

| Predicción $\hat{Y}$ | Realidad (Y): Positivo Y= 1 | Realidad (Y): Negativo Y=0 |
|---|---|---|
| Positivo $\hat{Y} = 1$ | TP | FP |
| Negativo $\hat{Y}=0$ | FN | TN |

$$P(\hat{Y}=1 \mid Y=1)$$

# True Positive Rate / Sensitivity / Recall

---

| Predicción $\hat{Y}$ | Realidad (Y): Positivo Y= 1 | Realidad (Y): Negativo Y=0 |
|---|---|---|
| Positivo $\hat{Y} = 1$ | TP | FP |
| Negativo $\hat{Y}=0$ | FN | TN |

$$TP/(TP+FN)$$

# Relación TPR y FNR

---

## True Positive Rate

| Predicción \ Realidad | Positivo | Negativo |
|---|---|---|
| Positivo | TP | FP |
| Negativo | FN | TN |

$$TP/(TP+FN)$$

$$P(\hat{Y}=1 \mid Y=1)$$

## False Negative Rate

| Predicción \ Realidad | Positivo | Negativo |
|---|---|---|
| Positivo | TP | FP |
| Negativo | FN | TN |

$$FN/(TP+FN)$$

$$P(\hat{Y}=0 \mid Y=1)$$

**1 -TPR = FNR**

# Ejercicio 3: Interpretación métricas

Considerar el siguiente escenario: se desarrolló un modelo de clasificación que busca predecir si un acusado cometerá otro delito grave tras su liberación. Una predicción positiva del modelo significa que el acusado rescindirá y, por lo tanto, no será liberado. Completar la interpretación de cada una de las siguientes métricas en este contexto:

1. Un falso positivo mantiene al acusado en prisión preventiva innecesariamente
2. Un falso negativo libera a alguien que reincide.
3. El accuracy representa es el porcentaje de decisiones tomadas correctamente.
4. TPR es la proporción de  personas que habrían reincidido a quienes se les denegó (correctamente) la libertad condicional.
5. FNR es la proporción de de personas que habrían reincidido y que fueron liberadas.

# False Positive Rate

| | | Realidad | |
|---|---|---|---|
| | | Positivo | Negativo |
| Predicción | Positivo | TP | FP |
| | Negativo | FN | TN |

$$FP/(FP+TN)$$

$$P(\hat{Y}=1 \mid Y=0)$$

# Relación entre FPR y TNR

## False Positive Rate

| Predicción \ Realidad | Positivo | Negativo |
|---|---|---|
| Positivo | TP | FP |
| Negativo | FN | TN |

$$FP/(FP+TN)$$

$$P(\hat{Y}=1 \mid Y=0)$$

## True Negative Rate

| Predicción \ Realidad | Positivo | Negativo |
|---|---|---|
| Positivo | TP | FP |
| Negativo | FN | TN |

$$TN/(FP+TN)$$

$$P(\hat{Y}=0 \mid Y=0)$$

**1 -FPR = TNR**

# False Discovery Rate

| | | Positivo | Negativo |
|---|---|---|---|
| **Predicción** | Positivo | TP | FP |
| | Negativo | FN | TN |

$$FP/(FP+TP)$$

$$P(Y=0|\hat{Y}=1)$$

# Relación FDR y PPV

## False Discovery Rate

| Predicción \ Realidad | Positivo | Negativo |
|---|---|---|
| Positivo | TP | FP |
| Negativo | FN | TN |

$$FP/(FP+TP)$$

$$P(Y=0|\hat{Y}=1)$$

## Positive Predictive Value

| Predicción \ Realidad | Positivo | Negativo |
|---|---|---|
| Positivo | TP | FP |
| Negativo | FN | TN |

$$TP/(FP+TP)$$

$$P(Y=1|\hat{Y}=1)$$

**1 -FDR = PPV**

# Relación entre FOR y NPV

## False Omission Rate

| Predicción \ Realidad | Positivo | Negativo |
|---|---|---|
| Positivo | TP | FP |
| Negativo | FN | TN |

$$FN/(FN+TN)$$

$$P(Y=1|\hat{Y}=0)$$

## Negative Predictive Value

| Predicción \ Realidad | Positivo | Negativo |
|---|---|---|
| Positivo | TP | FP |
| Negativo | FN | TN |

$$TN/(FN+TN)$$

$$P(Y=0|\hat{Y}=0)$$

**1 -FOR = NPV**

# Ejercicio 3: Interpretación métricas II

Considerar el siguiente escenario: se desarrolló un modelo de clasificación que busca predecir si un acusado cometerá otro delito grave tras su liberación. Una predicción positiva del modelo significa que el acusado rescindirá y, por lo tanto, no será liberado. Completar la interpretación de cada una de las siguientes métricas en este contexto:

1. FPR es la proporción de personas que fueron no fueron liberadas respecto de las que no reincidieron.
2. TNR es la proporción de de personas que fueron liberadas respecto de las que no reincidieron.
3. PPV es la proporción de personas que reinciden respecto de a quienes se les negó la libertad condicional.
4. NPV es la proporción de de personas que no reincidieron respecto de las que fueron liberadas.

**Tarea**

# Decisiones de Contratación o Admisión

---

Supongamos que una universidad toma decisiones sobre qué estudiantes aceptar en su programa. Aquí, X es el expediente académico del solicitante, A es un grupo destacado legalmente protegido, Y representa si el solicitante tendría éxito en el programa y C(X,A) decide si admitir (1) o rechazar (0) a un solicitante. Tenga en cuenta que el resultado Y no está bien definido. Definiremos "exitoso" como "si el solicitante se graduará del programa"; este es un indicador que merece su crítica.

1. Un falso positivo es un
2. Un falso negativo es
3. TPR es la proporción.
4. FPR es la proporción.
5. FNR es la proporción.
6. PPV es

# Ejercicio

Duración: 10 minutos en sala de grupos

1. Nos dividiremos en los grupos definidos para el Trabajo Práctico.
2. Cada grupo interpretará qué significan las métricas vistas.
3. Volvemos a la sala principal y cada grupo compartirá sus interpretaciones.

Link al enunciado:
http://tiny.cc/equidad_clase3
(ejercicio 2)

Próxima clase:
continuaremos con criterios de *fairness*