

Equidad en Aprendizaje Automático

Análisis de Sesgos y Mitigación en Bank Marketing

Trabajo Práctico Integrador

1er Cuatrimestre 2026

Universidad Nacional de San Martín (UNSAM)

1. El Dataset: Bank Marketing

Motivación

Predecir si un cliente **suscribirá a un plazo fijo** para optimizar campañas de marketing telefónico.

Naturaleza de los Datos

- 45,211 instancias (llamadas telefónicas).
- Variables sociodemográficas y macroeconómicas (Euribor, tasas de empleo).

Variable Protegida (Foco de Equidad)

- `job` (Ocupación) como proxy de género (ej. roles históricamente feminizados como "housemaid" vs masculinizados como "blue-collar").

2. Datasheets for Datasets (Contexto)

Origen y Validación

- Obtenido del UCI Machine Learning Repository.
- Los datos no provienen de encuestas, sino de **registros administrativos reales** de un banco portugués (2008-2010).
- La validación del éxito de la campaña fue determinística (cruce con bases transaccionales).

Implicancias Éticas

- La recolección directa de sistemas bancarios hereda los sesgos históricos de aprobación y acceso a capital del banco.
- Los "descartados" por el modelo no volverán a ser llamados, perpetuando su exclusión financiera.

3. Sesgos Potenciales Iniciales

Existen fuertes desbalances estructurales en los datos:

- **Etiquetas:** ~90% de los contactos dicen "no".
- **Educación:** El nivel secundario es mayoría absoluta.
- **Demografía:** Grupos como solteros o jubilados están fuertemente subrepresentados frente a adultos casados.

Riesgo Identificado:

El modelo puede priorizar inadvertidamente a los grupos mayoritarios (aprendiendo sus patrones), siendo ineficaz para captar a las minorías.

4. Clasificación Base y Rendimiento Global

Antes de analizar la equidad, entrenamos un modelo **Random Forest Classifier** estándar.

Métricas del Modelo Base (Global)

- Es excelente prediciendo el "No" (alta Accuracy global empujada por la clase mayoritaria).
- Sufre para predecir correctamente el "Sí" en casos ambiguos.


El Costo del Error: Falsos Negativos

- **Falso Negativo (FN):** Predecir que el cliente *no* aceptará, cuando en realidad *sí* lo haría.
- **Impacto:** Pérdida directa de un cliente potencial (costo de oportunidad real).
- *Un Falso Positivo solo cuesta el tiempo operativo de hacer una llamada inútil.*

5. Evaluación Inicial (**job** como proxy)

Evaluación del modelo base segmentando por ocupación (proxy de género).

- Las tasas de verdaderos positivos (captar al cliente real) varían drásticamente.
- Trabajos "feminizados" reciben predicciones negativas desproporcionadas, no por incapacidad de ahorro, sino por correlaciones espurias del dataset histórico.



6. Conceptos de Equidad (Fairness)

Statistical Parity

Misma proporción de predicciones positivas para todos los grupos. *Irreal si la disposición real a suscribirse varía.*

Equalized Odds

Mismas tasas de verdaderos positivos (TPR) y falsos positivos (FPR) en todos los grupos. *Muy estricto.*

Predictive Parity

Mismo Precision (Valor Predictivo Positivo) entre grupos.

Criterio Elegido: Equal Opportunity (Igualdad de Oportunidades)

Como el **Falso Negativo** es el error más costoso, exigimos que la **Tasa de Verdaderos Positivos (TPR)** sea igual para todos.


Si un cliente realmente va a suscribirse, el modelo debe detectarlo sin importar su ocupación.

7. Análisis Cuantitativo de Sesgo (Pre-mitigación)

Evaluación matemática de la disparidad antes de intervenir.

Utilizando el módulo de la diferencia como medida de disparidad:


- Se observa que el modelo original viola fuertemente la Igualdad de Oportunidades.
- La diferencia de TPR entre el grupo privilegiado y desfavorecido excede el umbral de tolerancia ética aceptable.



8. Mitigación: Reweighing (Pre-procesamiento)

Técnica: Asigna "pesos" a los datos de entrenamiento para balancear la importancia empírica de grupos desfavorecidos.


- **No altera los datos**, solo modifica su distribución de peso interno.
- Evita que el modelo penalice a grupos minoritarios durante el aprendizaje.
- *Resultado Empírico:* Mejora leve, pero insuficiente ante los sesgos estructurales profundos de este dataset bancario.



9. Mitigación: Equalized Odds (Post-procesamiento)

Técnica: Modifica los umbrales de decisión del modelo *después* de que fue entrenado, forzando matemáticamente la igualdad de TPR.

- Intervención directa y potente sobre el resultado final emitido.
- **Garantiza la Igualdad de Oportunidades** forzando los ratios.
- *Costo:* Impacta de forma visible y directa en el "Accuracy" global del modelo.



10. Resumen Numérico Comparativo

Al aplicar las técnicas utilizando la librería **Holistic AI**, observamos la siguiente progresión empírica:


Modelo	Accuracy Global	TPR Difference (Sesgo)	Cumple Equal Opportunity?
Random Forest Base	~ 90.0%	Alto	 No
RF + Reweighing	~ 89.8%	Medio-Alto	 No (Mejora marginal)
RF + Equalized Odds	~ 87.5%	Cercano a 0	 Sí

(Nota: Valores representativos para ilustrar la tendencia del trade-off observado).

11. Fairness vs. Performance

El trade-off matemático es inevitable: Mitigar sesgos profundos conlleva un costo en el rendimiento general.

- Igualar oportunidades obliga al modelo a cometer errores "intencionales" desde la perspectiva de la exactitud pura.
- **Decisión del Negocio:** ¿Cuánto *Accuracy* estamos dispuestos a sacrificar en la campaña para garantizar un trato justo a todos los clientes?



12. Reflexión en el Mundo Real

Más allá de los números

Un modelo sesgado que deniega sistemáticamente oportunidades genera **ciclos de retroalimentación negativos**:

Grupos marginados no son contactados → no generan historial → el modelo futuro aprende que "no son propensos al éxito".

Conclusión Final de la Materia:

Los algoritmos y los datos no son neutros. Mitigar sesgos no es solo un ajuste técnico; es un imperativo ético para no amplificar ni automatizar inequidades estructurales a gran escala.

¿Preguntas?