

Equidad en Aprendizaje Automático

Análisis de Sesgos y Mitigación en Bank Marketing

Trabajo Práctico Integrador

Integrantes: Tomás Nadal, Alejandro Echeverri, Matías Bacalhau, Rocío Rivera

1er Cuatrimestre 2026 | Universidad Nacional de San Martín (UNSAM)

1. El Dataset: Bank Marketing

Motivación

Predecir si un cliente **suscribirá a un plazo fijo** para optimizar campañas de marketing telefónico.

Naturaleza de los Datos

- **45,211 instancias** (llamadas telefónicas).
- Variables sociodemográficas y macroeconómicas (Euribor, tasas de empleo).
- **Preprocesamiento Clave:** Exclusión de la variable `duration` para evitar el riesgo de *Data Leakage*.

Variable Protegida (Foco de Equidad)

- `job` (Ocupación) como **proxy de género** (ej. roles históricamente feminizados como "housemaid" vs masculinizados como "blue-collar").

2. Datasheets for Datasets (Contexto)

Origen y Validación

- Obtenido del UCI Machine Learning Repository.
- Los datos no provienen de encuestas, sino de **registros administrativos reales** de un banco portugués (2008-2010).
- La validación del éxito de la campaña fue determinística (cruce con bases transaccionales).

Implicancias Éticas

- La recolección directa hereda los sesgos de perfilamiento del banco. Al decidir a quién ofrecer instrumentos de ahorro (cuyos rendimientos se pagan con capital del banco), se discrimina a grupos vulnerables.
- Los "descartados" por el modelo no volverán a ser llamados, perpetuando su exclusión de herramientas de ahorro e inclusión financiera.

3. Sesgos Potenciales Iniciales

Existen fuertes desbalances estructurales en los datos:

- **Etiquetas:** ~90% de los contactos dicen "no".
- **Educación:** El nivel secundario es mayoría absoluta.
- **Demografía:** Grupos como solteros o jubilados están fuertemente subrepresentados frente a adultos casados.

Riesgo Identificado:

El modelo puede priorizar inadvertidamente a los grupos mayoritarios (aprendiendo sus patrones), siendo ineficaz para captar a las minorías.

4. Clasificación Base y Rendimiento Global

Antes de analizar la equidad, entrenamos un modelo **Random Forest Classifier** estándar.

Métricas del Modelo Base (Global)

- Es excelente prediciendo el "No" (alta Accuracy global empujada por la clase mayoritaria).
- Sufre para predecir correctamente el "Sí" en casos ambiguos.


El Costo del Error: Falsos Negativos

- **Falso Negativo (FN):** Predecir que el cliente *no* aceptará, cuando en realidad *sí* lo haría.
- **Impacto:** Pérdida directa de un cliente potencial (costo de oportunidad real).
- *Un Falso Positivo solo cuesta el tiempo operativo de hacer una llamada inútil.*

5. Evaluación Inicial (**job** como proxy)

Evaluación del modelo base segmentando por ocupación (proxy de género).

- **Hallazgo clave:** La TPR del grupo feminizado fue **18.49%** vs **19.96%** del resto — una diferencia de solo **1.46%**.
- El problema real no era discriminación: **ambos grupos tenían un Recall inferior al 20%**. El algoritmo era ineficaz para captar inversores reales en *todos* los grupos por igual.



6. Conceptos de Equidad (Fairness)

Statistical Parity

Misma proporción de predicciones positivas para todos los grupos. *Irreal si la disposición real a suscribirse varía.*

Equalized Odds

Mismas tasas de verdaderos positivos (TPR) y falsos positivos (FPR) en todos los grupos. *Muy estricto.*

Predictive Parity

Mismo Precision (Valor Predictivo Positivo) entre grupos.

Criterio Elegido: Equal Opportunity (Igualdad de Oportunidades)

Como el **Falso Negativo** es el error más costoso, exigimos que la **Tasa de Verdaderos Positivos (TPR)** sea igual para todos.


Si un cliente realmente va a suscribirse, el modelo debe detectarlo sin importar su ocupación.

7. Análisis Cuantitativo de Sesgo (Pre-mitigación)

Evaluación matemática de la disparidad antes de intervenir.

Utilizando el módulo de la diferencia como medida de disparidad:


- **Hallazgo inesperado:** El modelo original (Baseline) resulta ser muy equitativo, cumpliendo con holgura **todas** las métricas con un umbral de tolerancia del 10%:
 - Statistical Parity: **0.0018** ✓
 - Equal Opportunity (TPR): **0.0146** ✓
 - Predictive Parity: **0.0217** ✓



8. Mitigación: Reweighing (Pre-procesamiento)

Técnica: Asigna "pesos" a los datos de entrenamiento para balancear la importancia empírica de grupos desfavorecidos.

- **No altera los datos**, solo modifica su distribución de peso interno.
- Evita que el modelo penalice a grupos minoritarios durante el aprendizaje.
- *Resultado Empírico:* Como el modelo base ya era equitativo, aplicar este pre-procesamiento generó fluctuaciones menores, degradando levemente algunas métricas en el set de prueba.



9. Enfoque Alternativo: Ajuste Manual de Umbral


Antes de recurrir a un post-procesamiento complejo, evaluamos una intervención directa para priorizar la captación comercial (reducir Falsos Negativos).

- **Técnica:** Analizamos las métricas internas del Random Forest y bajamos el umbral de decisión para clasificar como "Sí" de `0.50` a `0.30`.
 - **Resultado:** Se **duplicaron** los Verdaderos Positivos (**214** → **484** clientes captados), reduciendo los Falsos Negativos de más de 800 a 574, **sin afectar la equidad**.
 - **Conclusión:** A veces un ajuste empírico simple y guiado por el negocio es más transparente y efectivo que forzar restricciones matemáticas a ciegas en todo el pipeline.

10. Mitigación: Equalized Odds (Post-procesamiento)

Técnica: Modifica los umbrales de decisión del modelo *después* de que fue entrenado, forzando matemáticamente la igualdad de TPR.

- Intervención directa y potente sobre las predicciones emitidas.
- **¿Qué ocurrió aquí?:** Aplicar este mitigador estricto sobre un modelo que *ya era justo* terminó **empeorando** la equidad (aumentó la diferencia de TPR).
- **Conclusión:** Forzar la igualdad matemática alterando (haciendo "flip" a) predicciones de un modelo balanceado introduce ruido y degrada los resultados.



11. Resumen Numérico Comparativo

Al aplicar las técnicas utilizando la librería **Holistic AI**, observamos los siguientes resultados en las métricas de disparidad:

Modelo	TPR Difference	Disparate Impact	Evaluación de Equidad
Random Forest Base	0.0146	1.049	✓ Muy Justo
RF + Reweighing	0.0179	0.972	✓ Justo (leve ruido)
RF + Equalized Odds	0.0673	1.254	✗ Empeora la equidad

(Nota: El baseline resultó ser el mejor modelo. Aplicar mitigadores por defecto puede ser contraproducente).

12. Extrapolación: Nivel Educativo (Ej 5)


Para validar la robustez de la metodología, replicamos el análisis de equidad utilizando la variable **education** (Universitarios vs No Universitarios).

- **El Umbral 0.30 como Base:** Adoptamos el umbral ajustado empíricamente como nuestro nuevo modelo base comercial, ya que demostró mejorar los Verdaderos Positivos.
- **Prueba de Mitigadores:** Aplicamos *Reweighting* y un *Threshold Adjustment* iterativo específico por grupo educativo.
- **Conclusión Consistente:** Confirmamos la misma tendencia que con la variable **job**. Nuestro modelo base ya presentaba disparidades ínfimas, por lo que intervenir forzosamente por subgrupos no aportó ganancias significativas de equidad.

13. Lecciones sobre la Mitigación

Nuestro análisis nos dejó una enseñanza contra-intuitiva pero fundamental en la práctica:

- **No asumas el sesgo, mídelo:** El modelo base resultó ser altamente equitativo de forma natural.
- **Más mitigación no siempre es mejor:** Intervenir agresivamente con algoritmos de *post-processing* terminó añadiendo ruido y empeorando las métricas de sesgo.
- **Pruebas de estrés:** Un umbral estándar (0.1) puede ser muy permisivo; es clave analizar la robustez con umbrales más estrictos (0.01).



14. Reflexión en el Mundo Real

Más allá de los números

Un modelo sesgado que deniega sistemáticamente oportunidades genera **ciclos de retroalimentación negativos**:

Grupos marginados no son contactados → no generan historial → el modelo futuro aprende que "no son propensos al éxito".

Recomendación Operativa para el Banco:

Modificar procesos de recolección para obtener el género explícito voluntariamente, abandonando la inexactitud de los proxies.

Conclusión Final de la Materia:

Los algoritmos y los datos no son neutros. Mitigar sesgos no es solo un ajuste técnico; es un imperativo ético para no amplificar ni automatizar inequidades estructurales a gran escala.

¡Muchas gracias!

¿Tienen alguna pregunta?