

Equidad en Aprendizaje Automático

Resultados del Trabajo Práctico: Bank Marketing

1. El Dataset: Bank Marketing

Motivación

Predecir si un cliente **suscribirá a un plazo fijo** para optimizar campañas de marketing.

Naturaleza de los Datos

- **45,211 instancias** (llamadas telefónicas).
- Variables sociodemográficas y económicas.

Variable Protegida (Foco de Equidad)

- **job** (Ocupación) como proxy de género (ej. "housemaid" vs "admin").

2. Sesgos Potenciales

Fuertes desbalances estructurales en los datos:

- **Etiquetas:** ~90% de los contactos dicen "no".
- **Educación:** Nivel secundario es mayoría absoluta.
- **Demografía:** Grupos como solteros o jubilados están fuertemente subrepresentados.

Riesgo:

El modelo puede priorizar inadvertidamente a los grupos mayoritarios, siendo ineficaz para captar a las minorías.

3. El Costo del Error

Al entrenar el modelo, evaluamos el impacto del error:


El Falso Negativo (FN) es el más crítico.

- **Falso Negativo:** Predecir que el cliente *no* aceptará, cuando en realidad *sí* lo haría.
- **Impacto:** Pérdida directa de un cliente potencial (costo de oportunidad).
- *Un Falso Positivo solo cuesta el tiempo de una llamada.*

4. Evaluación Inicial (job como proxy)

Evaluación del modelo sin mitigación utilizando la ocupación como proxy de género.

- Las tasas de verdaderos positivos (captar al cliente real) varían drásticamente.
- Trabajos "feminizados" reciben predicciones negativas desproporcionadas debido a correlaciones espurias del dataset.




5. Criterios de Equidad (Fairness)

Evaluación de criterios matemáticos de sesgo.

Criterio Relevante: Igualdad de Oportunidades

Como el Falso Negativo es el peor error, exigimos que la **Tasa de Verdaderos Positivos (TPR)** sea igual para todos los grupos.


Si un cliente realmente va a suscribirse, el modelo debe detectarlo sin importar su ocupación.



6. Mitigación: Reweighing (Pre-procesamiento)

Técnica: Asigna "pesos" a los datos de entrenamiento para balancear la importancia de grupos desfavorecidos.


- **No altera los datos**, solo su distribución de peso.
- Evita que el modelo penalice a grupos minoritarios.
- *Resultado:* Mejora leve, pero suele ser insuficiente ante sesgos profundos.



7. Mitigación: Equalized Odds (Post-procesamiento)

Técnica: Modifica los umbrales de decisión del modelo ya entrenado, forzando matemáticamente la igualdad de TPR y FPR.

- Intervención directa sobre el resultado final.
- **Garantiza la Igualdad de Oportunidades.**
- *Costo:* Impacta negativamente en el "Accuracy" global del modelo.




8. Fairness vs. Performance

Mitigar sesgos conlleva un costo en el rendimiento matemático general.

El Trade-off

- Igualar oportunidades obliga al modelo a cometer errores "intencionales" para no discriminar.
- **Decisión:** ¿Cuánto *Accuracy* sacrificamos para garantizar un trato justo?



9. Reflexión en el Mundo Real

Más allá de los números

Un modelo sesgado genera **ciclos de retroalimentación negativos**:

Grupos marginados no acceden al producto → no generan historial → el modelo futuro aprende que "no son exitosos".

Conclusión:

Los algoritmos no son neutros. Mitigar sesgos es un imperativo ético para no amplificar inequidades estructurales a gran escala.